

Rapport d'anonymisation des données CRM

Titre du projet	Extraction anonymisée des donnée CRM à l'intention du service de	
	performance commerciale	

Version	Auteur	Description	Date
V1	PAOLI J.	Rapport	10.01.2022

Introduction

L'entreprise se trouve dans une situation d'urgence suite à une sanction de la CNIL imposant une limitation temporaire de six mois sur le traitement des données personnelles.

En attendant une régularisation, il est essentiel pour elle de se conformer aux directive de la CNIL tout en permettant la continuité des activités de l'entreprise, notamment celles de l'équipe de performance commerciale.

Pour répondre à ces enjeux, une extraction anonymisée des données du CRM a été réalisée, en suivant des objectifs précis :

- Garantir la suppression des données personnelles litigieuses
- Anonymiser le fichier obtenu afin d'éviter toute identification des clients
- Limiter l'accès aux données tarifaires détaillées, jugées sensibles et non nécessaires pour l'équipe destinataire.

Microsoft Power Query (via Microsoft Excel) a été choisi comme outil de transformation et d'anonymisation ; en l'absence d'un logiciel ETL dédié.

Ce rapport documente les étapes de nettoyage et d'anonymisation effectuées sur la base de données CRM.



Contenu du rapport :

Préconisations

Il convient avant de commencer à parler des traitements effectués; d'établir des préconisations pour toutes les futurs bases de données:

- Limiter la collecte de données à ce qui est strictement nécessaire, avec un soin particulier pour les données sensibles comme les données médicales
- Proportionner les données collectées; car si une adresse est une donnée nécessaire, la localisation GPS exacte du domicile est excessive
- Mettre en place une communication claire sur l'utilisation qui sera faite des données
- Mettre en place une politique de conservation des données, avec des durées limitées, notamment pour les contrats avortés; et surtout offrir la possibilité aux prospects de faire supprimer leurs données via une procédure claire et accessibles
- Mettre en place des services dédiés à la protection des données (DPO par exemple)

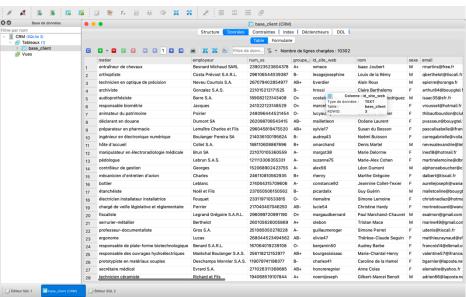
II. Les traitements effectués

Une fois les préconisation donnée, il faut commencer le traitement de la base de donnée.

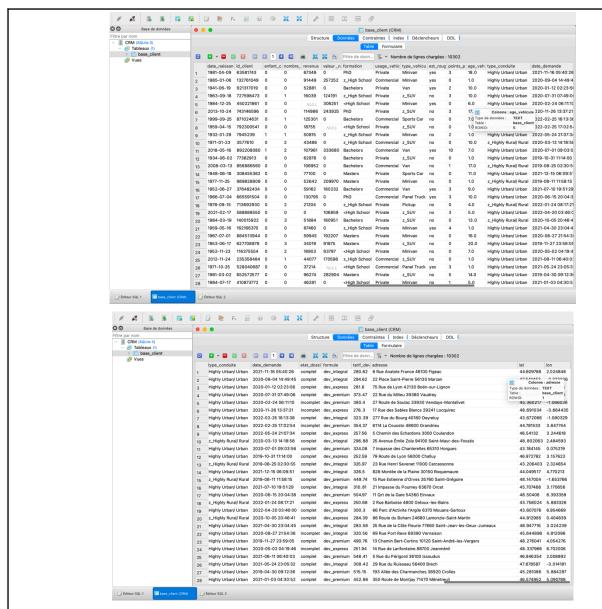
A. L'extraction de la base CRM

La 1^{ère} étape consiste à télécharger le fichier dans un logiciel permettant de lire et de travailler sur les bases en langage SQL;

Ici en l'occurrence SQLite Studio:







On peut déjà observer ici que notre base contient des données inutiles. Pour rappel, cette base concerne des contrats d'assurance automobile; les données médicales comme le groupe sanguin ou le numéro de sécurité sociale sont donc inutiles et surtout il est interdit de les mettre dans ce type de base de donnée sans sécurité spécifique (voir le guide de conformité); de même que si le nombre d'enfants en conduite accompagnée est logique, le nombre d'enfant total dépasse les besoins de l'Assureur, de même que la géolocalisation des maisons, l'adresse est amplement suffisante. Enfin, on détermine si le reste des données sont pertinentes et/ou adéquates en l'espèce; comme le préconise le RGPD.

B. La Sélection des données

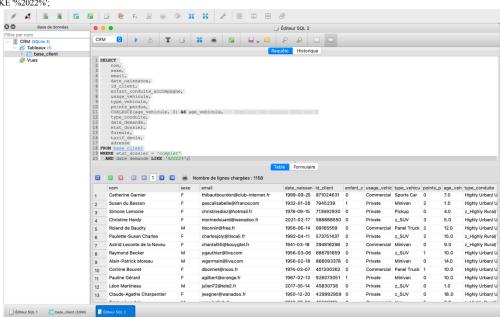
Une fois les données examinées, et sélectionnées il faut réaliser un tri via le logiciel afin d'obtenir une « base » fonctionnelle ;



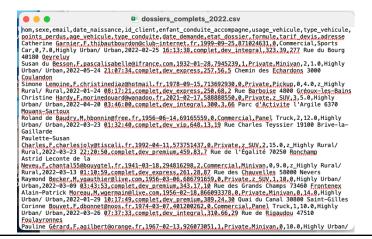
On demande alors au logiciel de ne garder que les colonnes indispensables; qui concernent les dossier complets -donc des clients actuels, les clients qui n'ont finalement pas souscris sont non pertinents. On rajouetra comme critère celui de l'année en cours, 2022 afin de faciliter les prochaines étapes de travail.

La formule est la suivante :

SELECT nom, email date naissance, id_client, enfant_conduite_accompagne, usage vehicule, type_vehicule, points perdus. COALESCE(age vehicule, 0) AS age vehicule, -- Remplace les valeurs NULL par 0 date demande etat dossier, formule, tarif devis adresse FROM base_client WHERE etat dossier = 'complet' AND date_demande LIKE '%2022%';



On obtient alors un premier fichier .CSV qui sera notre base de travail sur Powe Query.





C. L'Anonymisation des données

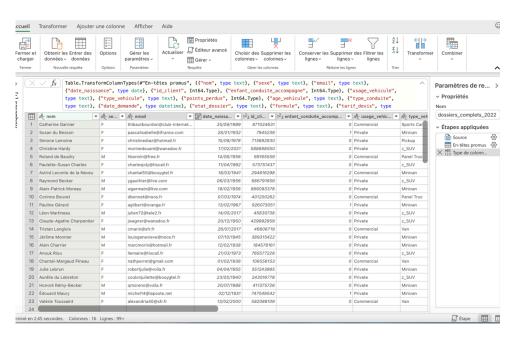
Dernière étape, la plus importante; il s'agit désormais, grâce à Power Query d'anonymiser cette base de données régularisée; afin que le Service en charge de la performance commerciale puisse l'exploiter dans les limites fixées par la sanction de la CNIL.

Il y a ici deux étapes, d'abord l'élimination des colonnes d'identification directe; puis l'anonymisation renforcée de celle d'identification indirecte.

a. Suppression des colonnes d'identification directe

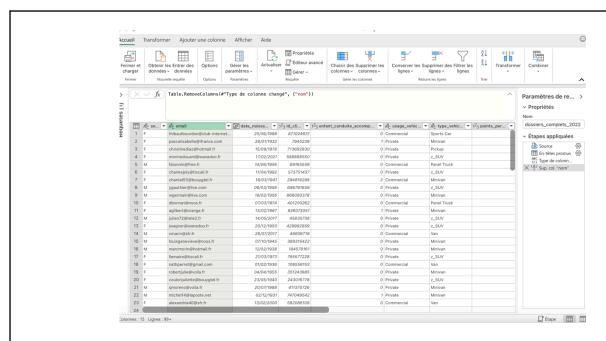
C' est l'étape la plus simple ; il s'agit de supprimer toutes les colonnes pouvant directement permettre l'identification des clients.

On supprime donc le nom, l'adresse physique et e-mail ; mais aussi l'ID client et l'identifiant de l'espace client. Pour cela on selectionne la colonne dans Query et on appuie sur supprimer. Illustration avec la colonne « *nom* » avant suppression :



Après suppression;



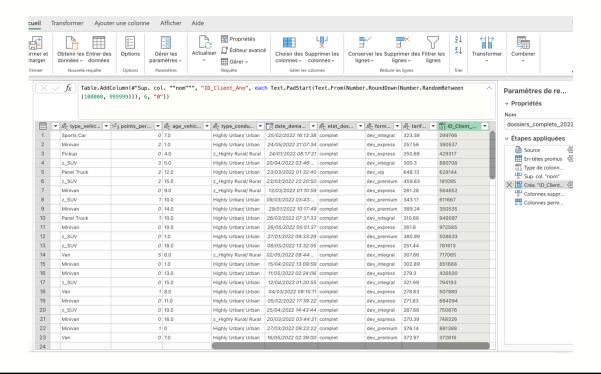


b. L'Anonymisation renforcée des colonnes d'identification indirecte

Une fois débarrasser des colonnes permettant d'identifier directement les clients ; il va falloir renforcer l'anonymisation des données qui pourraient une fois regroupées permettre une identification ;

Ainsi, les client se veront appliquer un ID_Ano pour remplacer leur ID client, pour les retrouver plus facilement sans compromettre leur anonymat. La formule « Table.AddColumn(#"Sup. col. ""nom""", "ID Client Ano", each

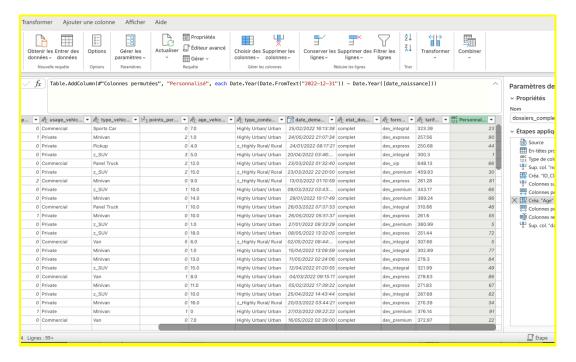
Text.PadStart(Text.From(Number.RoundDown(Number.RandomBetween(100000, 999999))), 6, "0"))» sera appliquée afin de créer un Index randomisé



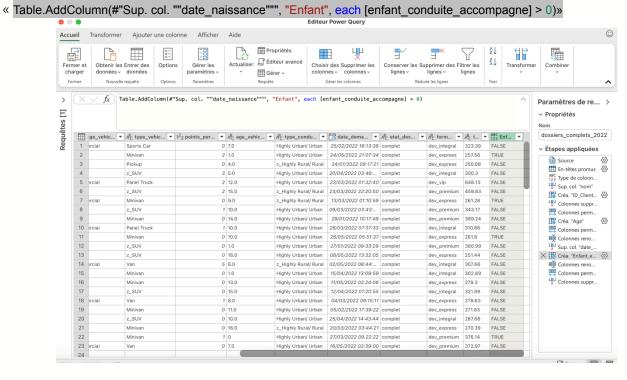


Puis, leur date de naissance sera remplacée par leur âge ; ce qui permettra toujours de faire des statistiques mais qui empêchera une identification trop précise ;

« Table.AddColumn(#"Colonnes permutées", "Personnalisé", each Date.Year(Date.FromText("2022-12-31")) - Date.Year([date_naissance]))»



Enfin, la colonne permettant de savoir combien d'enfants en conduite accompagnée a le client, a été remplacée par une colonne avec une fonction booléenne -true/false-



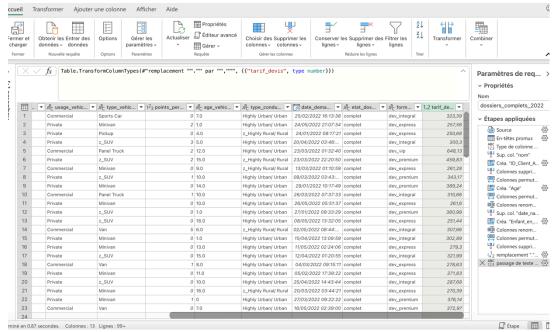


D. Le cas des données tarifaires de devis

Ici, il ne s'agi pas d'anonymisation au sens propre, mais de dissimuler des informations sensibles à un service qui a besoin de connaître l'intervalle, ici des devis, mais dont le chiffre exacte relève du secret.

L'entreprise a donc besoin que ces données soient « anonymisées » ;

On commence donc par mettre les tarifs en nombre décimaux ; «Table.ReplaceValue(#"Colonnes supprimées 1", ".", ",", Replacer.ReplaceText, {"tarif_devis"})» puis « Table.TransformColumnTypes(#"remplacement ""."" par "",""", {{"tarif_devis", type number}})»

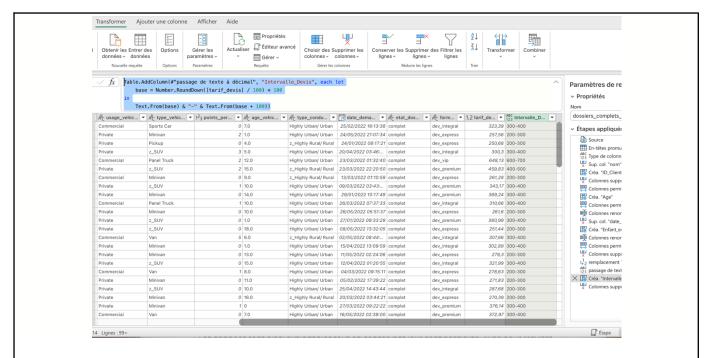


Pour ensuite les transformer en intervalle « Table.AddColumn(#"passage de texte à décimal", "Intervalle_Devis", each let

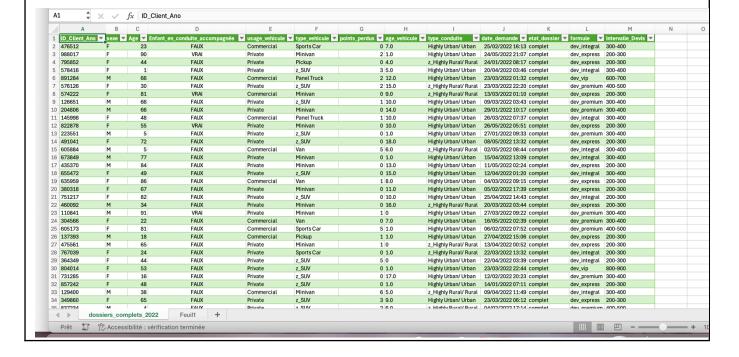
base = Number.RoundDown([tarif_devis] / 100) * 100

Text.From(base) & "-" & Text.From(base + 100))»





Les données sont ainsi exploitables tout en conservant leur confidentialité. Avec pour résultat final :



Conclusion

Toutes ces transformations et ce travail d'anonymisation ont permis de garantir la conformité au RGPD du document, tout en préservant l'utilité analytique du fichier.



Ils illustrent bien le défi que représente l'anonymisation; selon la nature des données; et la nécessité pour les entreprises d'être rigoureuse dès la création de leur base. Ainsi, grâce à Power Query, nous avons transformé les données pour éviter tout risque de réidentification.

Cette extraction est un premier pas vers une gestion plus responsable des données, qui s'appuiera sur des outils et des processus encore plus robustes à l'avenir.